INSTITUTO TECNOLÓGICO METROPOLITANO – ITM
Inteligencia de Negocios

Proceso ETL con los datasets de Airbnb Bogotá

Taller evaluativo 2

Integrantes
Julian Macea Cardona
David Lopez Cano

Repositorio
https://github.com/Juliam78/itm

Medellín, 11 de octubre de 2026

1. Introducción

Este informe documenta el desarrollo de un proceso ETL (extracción, transformación y carga) automatizado en Python sobre los datos públicos de Airbnb para Bogotá. El objetivo es convertir tres colecciones crudas –anuncios, reseñas y calendario de disponibilidad– en tablas limpias, consistentes y listas para análisis, dejando trazabilidad de cada paso en archivos de log.

Siguiendo el enunciado, la fuente del ETL es **exclusivamente MongoDB local**: los archivos *.csv.gz* se usaron solo una vez, para poblar la base de datos con el script *scripts/cargar_mongodb.py*, que además valida que el número de documentos de cada colección sea igual al de registros del archivo. El proceso está organizado en tres clases de Python:

- **Extraccion** (*src/extraccion.py*): conecta con MongoDB, valida que existan las colecciones *Listings*, *Reviews* y *Calendar*, y las carga en DataFrames de pandas registrando la conexión y la cantidad de registros.
- **Transformacion** (*src/transformacion.py*): limpia nulos y duplicados, normaliza precios, fechas, booleanos y texto, crea variables derivadas, categoriza precios y desanida los campos compuestos.
- **Carga** (*src/carga.py*): inserta las tablas en una base SQLite nueva, verifica que los conteos coincidan y exporta cuatro archivos XLSX.

Las tres etapas escriben en un único archivo de log por ejecución (*logs/log_YYYYMMDD_HHMM.txt*) con niveles INFO, WARNING y ERROR. El análisis exploratorio que justifica las decisiones está en *notebooks/exploracion_airbnb.ipynb*, que también lee los datos desde MongoDB usando la misma clase *Extraccion*.

Etapa	Entrada	Salida
Importación (una vez)	listings, reviews y calendar (.csv.gz)	Base MongoDB airbnb_bogota con 3 colecciones validadas
Extracción	MongoDB local	DataFrames listings, reviews y calendario agregado por mes
Transformación	DataFrames crudos	listings, hosts, listing_amenities, reviews, calendario_mensual
Carga	DataFrames limpios	sqlite/airbnb_bogota.db y 4 archivos XLSX en datos/salida/

2. Descripción del dataset

Los datos provienen de **Inside Airbnb**, proyecto que publica periódicamente la información de los anuncios de Airbnb por ciudad. Se usó el corte de Bogotá del **21 de junio de 2026**, el mismo que entrega el enunciado. Tras la importación, las tres colecciones de MongoDB quedaron con exactamente los mismos registros que los archivos fuente:

Colección	Documentos	Campos	Granularidad	Contenido principal
Listings	19 187	77 (de 90)	1 por anuncio	Ubicación, tipo de alojamiento, capacidad, precio, estadía mínima, disponibilidad, servicios (amenities), calificaciones y datos del anfitrión

Colección	Documentos	Campos	Granularidad	Contenido principal
Reviews	527 731	6	1 por reseña	Anuncio, fecha, autor y texto del comentario (octubre 2010 – junio 2026)
Calendar	7 003 255	5	1 por anuncio y día	Disponibilidad diaria de cada anuncio durante 365 días (21-jun-2026 a 21-jun-2027) y estadías mínima y máxima. No trae precio

Listings tiene 77 campos en MongoDB frente a 90 columnas del archivo porque la importación omite los valores vacíos: las 13 columnas que están vacías en el 100 % de los anuncios no se guardan en ningún documento. Las variables más relevantes para el análisis son *price* (precio por noche en COP, guardado como texto con formato "$284,294.01"), *room_type*, *neighbourhood_cleansed* (localidad), *accommodates*, *bedrooms*, *bathrooms*, *minimum_nights*, *availability_365*, *amenities* (lista JSON guardada como texto), *number_of_reviews*, *review_scores_rating* y las columnas *host_** del anfitrión. Las fechas llegan como texto ISO y los booleanos como "t"/"f".

3. Resumen del análisis exploratorio (EDA)

3.1 Entendimiento de los datos

Se revisaron *head()*, *shape* e *info()* de cada colección y el tipo con que llega cada campo desde MongoDB. El hallazgo central es que los campos clave no sirven para calcular sin convertirlos: el precio es texto con símbolo y separador de miles, las fechas son texto, *amenities* es una lista JSON serializada y los booleanos son letras.

3.2 Calidad de los datos

Aspecto	Resultado	Decisión
Columnas vacías	13 columnas 100 % nulas (datos del anfitrión que ya no se publican, neighbourhood, calendar_updated, instant_bookable)	Se descartan
Nulos estructurales	review_scores_* ≈ 4 265 (anuncios sin reseñas), bedrooms 2 959, bathrooms 1 066	No se imputan: inventarían información
Texto opcional	host_about 8 799, host_location 5 157, description 523	Se rellenan con "Sin información"
Precio faltante	195 anuncios (1,0 %)	Se conservan con rango "Sin precio"
Duplicados	0 por llave y 0 filas completas en las tres colecciones	Deduplicación por llave como control
Integridad	100 % de reseñas y filas de calendario apuntan a un anuncio existente	Filtro de huérfanos como control
Reseñas	191 sin comentario; 69 375 con <*br/*>; 800 con retorno de carro	Limpieza de texto; bandera sin_comentario

3.3 Valores atípicos

- **price**: mediana 161 460 COP, P95 497 580, P99 ≈ 1,3 millones y máximo 448 millones por noche. El criterio IQR×1.5 marcaría 1 410 anuncios; con IQR×3 quedan 659 (por encima de 591 386 COP). Los precios más altos (388–448 millones) son seis anuncios de un mismo anfitrión, habitaciones para dos personas: un error de captura evidente.

- **minimum_nights**: se concentra en 1–3 noches (mediana 1, Q3 = 3) con un segundo grupo en 30 noches. El criterio IQR marcaría el 21 % de los anuncios (más de 6 noches), así que se usa una regla de negocio: más de 30 noches (84 anuncios).
- **availability_365**: todos los valores están entre 0 y 365 (mediana 349). 3 508 anuncios tienen los 365 días libres, lo que suele indicar calendarios inactivos más que falta de demanda.

En ningún caso se eliminan los atípicos: se marcan con banderas (*precio_atipico*, *minimo_noches_atipico*) para que cada análisis decida si excluirlos. También se detectó que el **18 % de los precios** (3 453 anuncios) proviene de cotizaciones de 28 noches o más, que corresponden casi exactamente a los anuncios con estadía mínima mensual; su precio por noche ya incluye el descuento mensual (mediana 108 774 COP frente a 171 177 del resto).

4. Gráficas y hallazgos

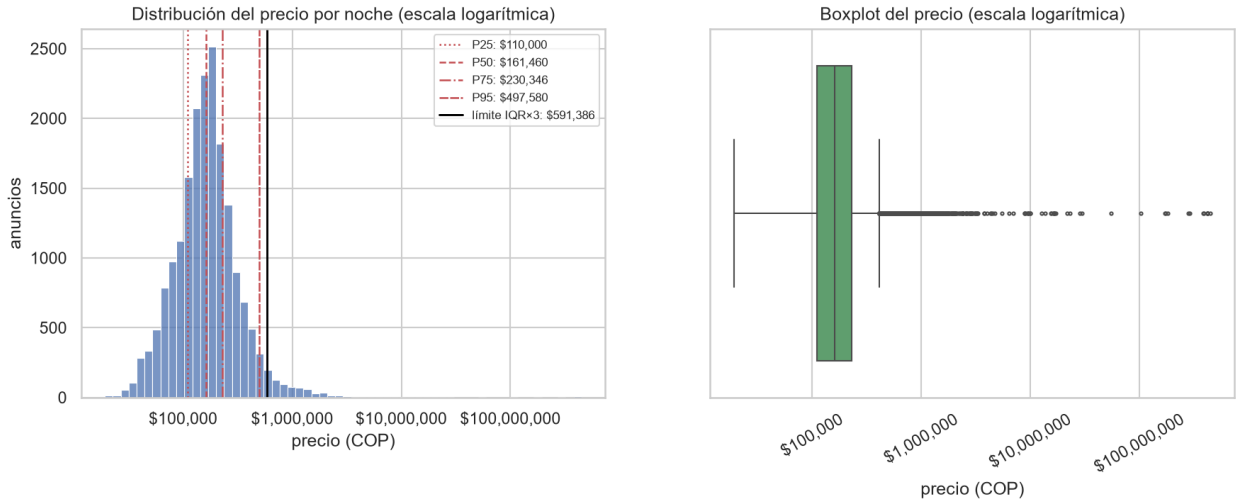


Figura 1. Distribución del precio por noche en escala logarítmica, con percentiles y límite de atípicos.

Hallazgo. El precio es muy asimétrico: solo en escala logarítmica la distribución es legible y aproximadamente normal. Por eso los resúmenes del informe usan la mediana y los atípicos se marcan con IQR×3 en vez de IQR×1.5.

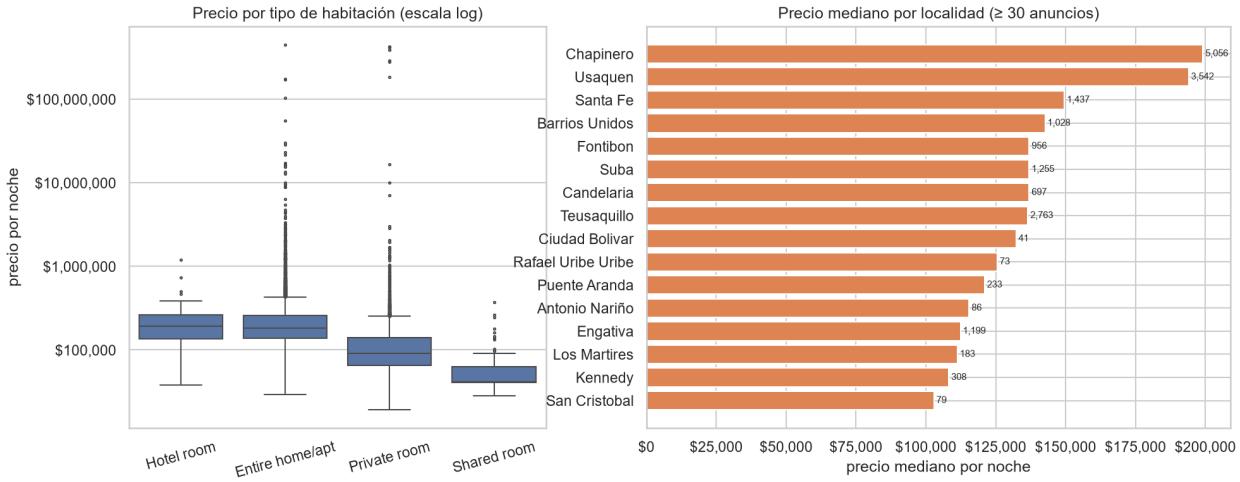


Figura 2. Precio por tipo de habitación (escala logarítmica) y precio mediano por localidad.

Hallazgo. El alojamiento completo domina la oferta (13 744 anuncios con precio, mediana 182 589 COP); la habitación privada cuesta la mitad (91 295) y la compartida 41 453. Chapinero (199 112 COP, 5 056 anuncios) y Usaquén (194 001, 3 542) concentran la oferta y los precios más altos; Kennedy y San Cristóbal están entre las localidades más económicas.

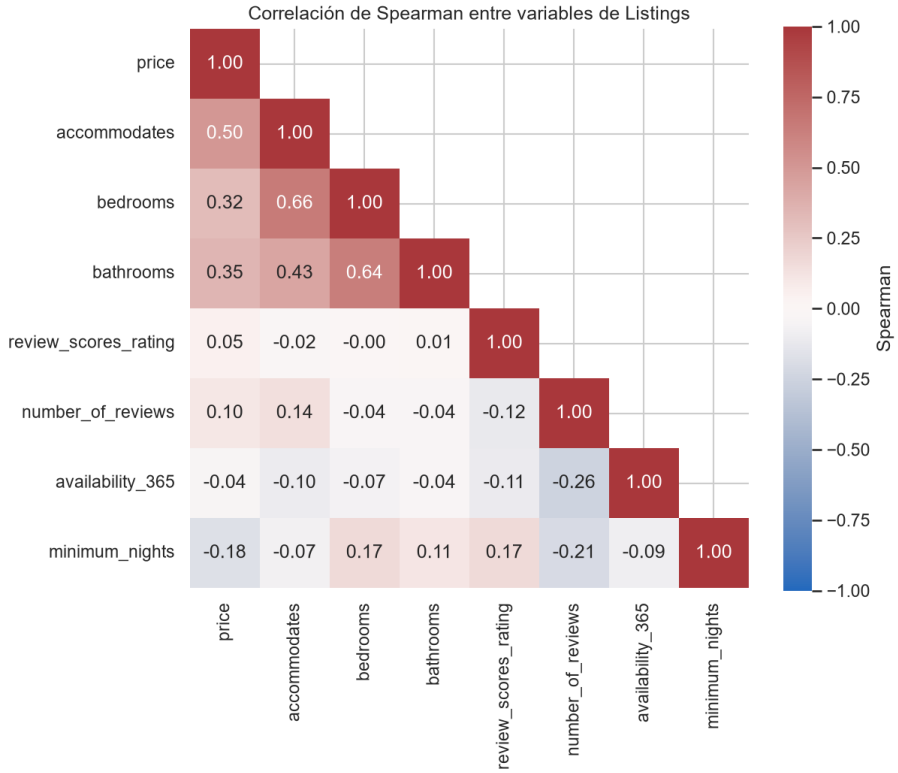


Figura 3. Correlación de Spearman entre variables numéricas de Listings.

Hallazgo. Se usó Spearman por la asimetría del precio. El precio depende sobre todo de la capacidad: accommodates (0,50), bathrooms (0,35) y bedrooms (0,32). La calificación (0,05) y el número de reseñas (0,10) casi no influyen. minimum_nights es negativa (−0,18) por el descuento de las estadías mensuales, y number_of_reviews se opone a availability_365 (−0,26): los anuncios más reseñados tienen menos noches libres.

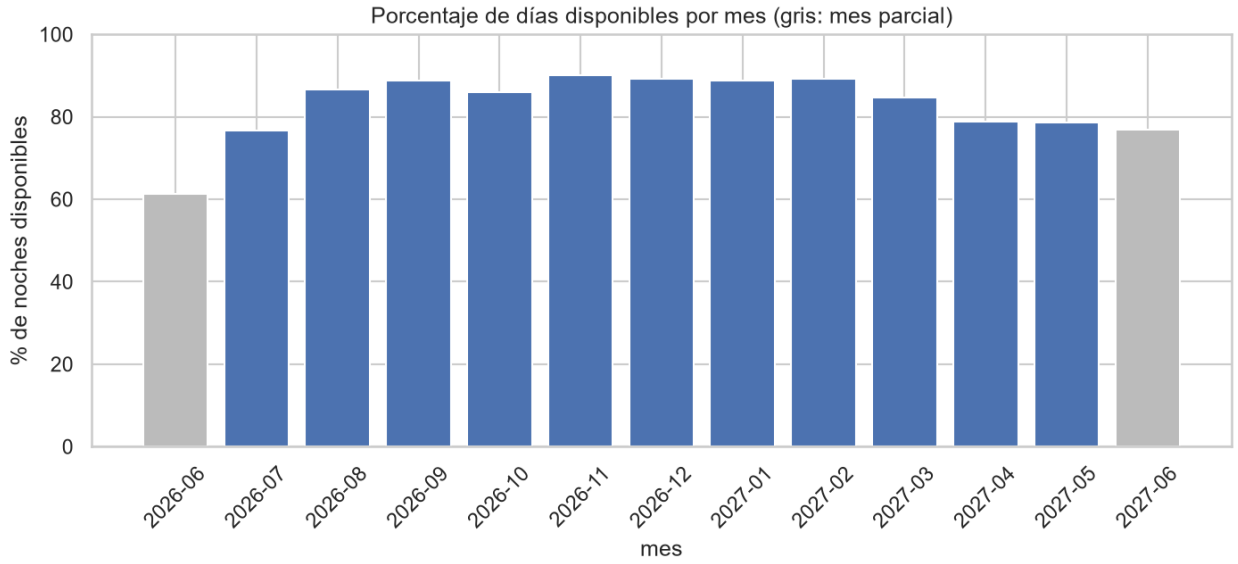


Figura 4. Porcentaje de noches disponibles por mes (gris: meses parciales).

Hallazgo. Julio de 2026 es el mes menos disponible (77 %) porque ya tiene reservas; entre septiembre de 2026 y febrero de 2027 la disponibilidad se estabiliza en 86–90 %. Junio de 2026 y junio de 2027 son meses parciales (≈9 y ≈21 días por anuncio), por lo que se compara la proporción de días disponibles y no la suma. La caída de marzo a junio de 2027 (≈79 %) se explica por fechas lejanas bloqueadas por los anfitriones, no por reservas.

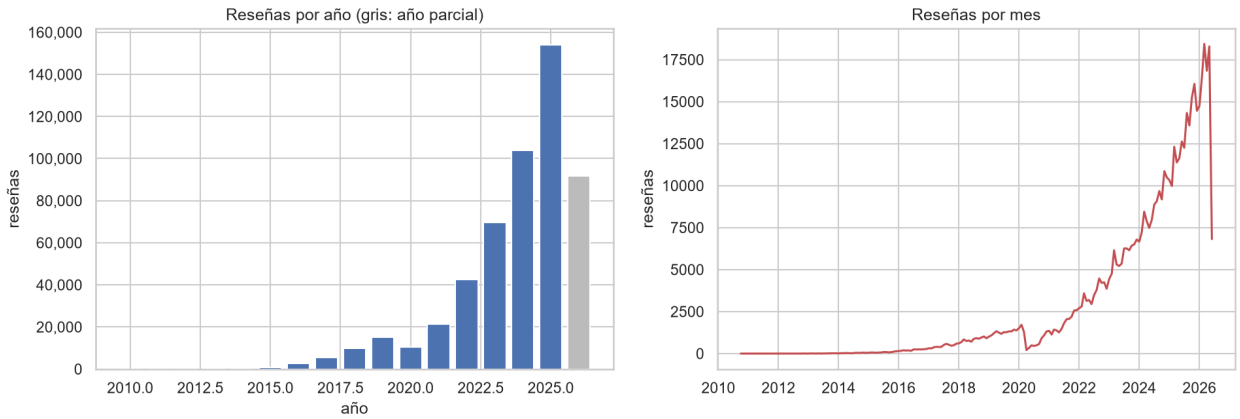


Figura 5. Reseñas por año y por mes (gris: año parcial).

Hallazgo. Las reseñas, usadas como aproximación de la demanda, crecen hasta 2019 (15 051), caen 31 % en 2020 por la pandemia y crecen con fuerza desde 2021 hasta 154 156 en 2025, diez veces lo de 2019. 2026 llega solo hasta el 21 de junio y ya suma 91 608.

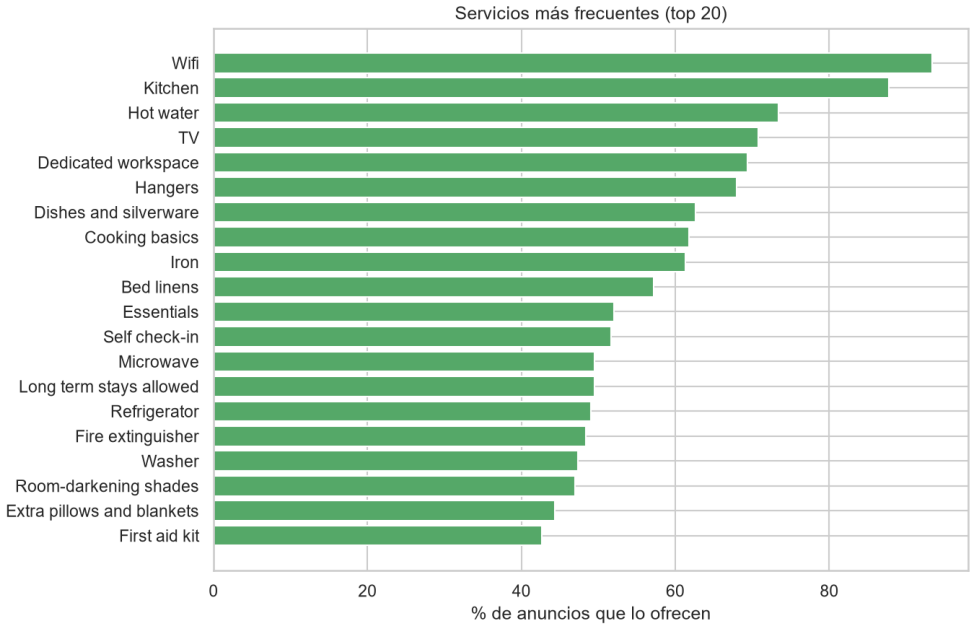


Figura 6. Servicios (amenities) más frecuentes.

Hallazgo. Cada anuncio ofrece en promedio 26,4 servicios y hay 3 588 servicios distintos. Los básicos (wifi, cocina, agua caliente) están en casi todos los anuncios y no diferencian la oferta.

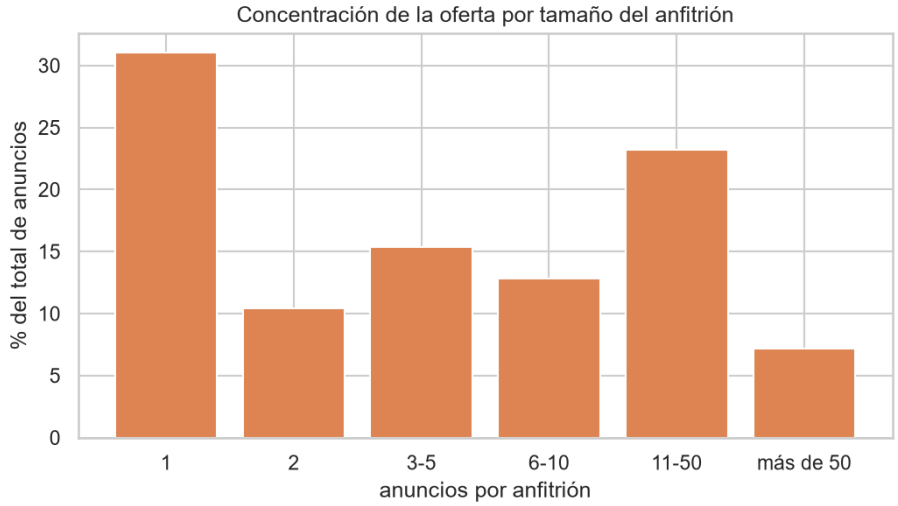


Figura 7. Concentración de la oferta según el número de anuncios por anfitrión.

Hallazgo. 8 335 anfitriones publican 19 187 anuncios. Solo el 31 % de los anuncios es de anfitriones con un único anuncio, mientras que el 30 % pertenece a anfitriones con más de 10 (17 anfitriones suman 1 372 anuncios): buena parte de la oferta la manejan operadores profesionales.

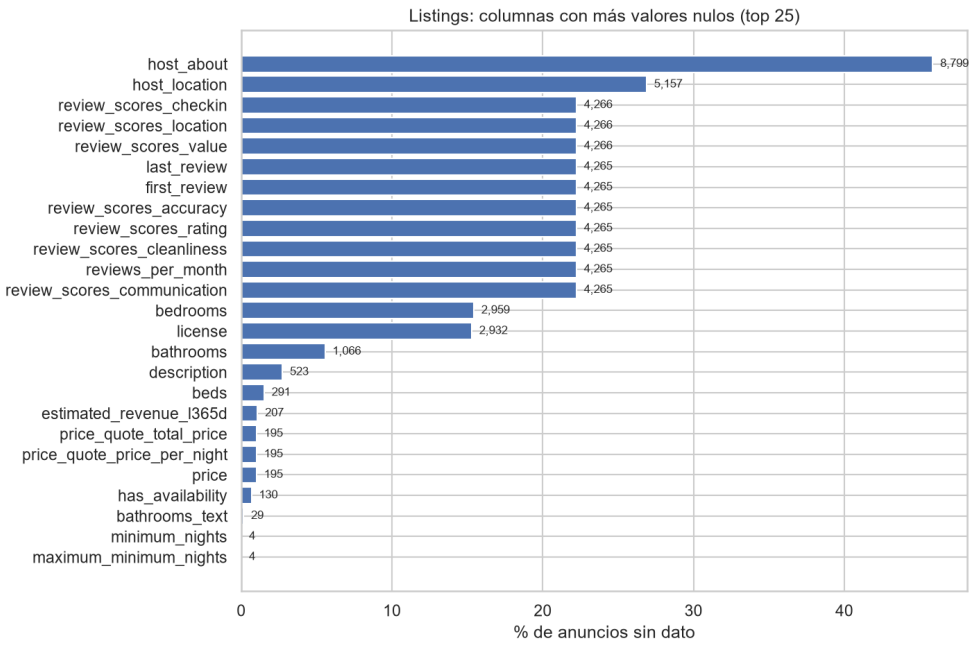


Figura 8. Columnas de Listings con más valores nulos.

5. Transformaciones aplicadas

Todas las transformaciones están implementadas en la clase *Transformacion* (no en el notebook) y cada una registra en el log lo que hizo y los registros antes y después.

Transformación	Detalle	Justificación
Llaves y duplicados	id → listing_id / review_id; deduplicación por llave; filtro de reseñas y calendario huérfanos	Llaves consistentes entre tablas; control ante recargas de MongoDB
Columnas vacías	Se eliminan las columnas 100 % nulas y price_quote_raw (JSON redundante)	No aportan información
Nulos	Texto descriptivo → "Sin información"; numéricos sin imputar	No inventar calificaciones ni tamaños
Moneda	price "$284,294.01" → 284294.01 (float), quitando "$" y ","	Permite calcular; formato verificado en el 100 % de los precios
Fechas	Texto → YYYY-MM-DD; de la fecha de la reseña se derivan anio, mes, dia y trimestre	Ordenar y agrupar por periodo
Rangos de precio	Económico ≤ 110 000 · Bajo ≤ 160 000 · Medio ≤ 230 000 · Alto ≤ 500 000 · Premium; "Sin precio"	Cortes cercanos a los percentiles 25, 50, 75 y 95
Atípicos	precio_atipico (IQR×3, 659) y minimo_noches_atipico (> 30 noches, 84); availability_365 validado en 0–365	Se marcan sin eliminar
Booleanos y texto	"t"/"f" → 1/0; se eliminan , caracteres de control y espacios repetidos	Sumar y promediar; evitar errores al escribir XLSX
amenities	Lista JSON → tabla listing_amenities (listing_id, amenity) + n_amenities	Consultar servicios sin parsear texto
Anfitrión	16 columnas host_* → tabla hosts (1 fila por host_id)	Eliminar redundancia: el anfitrión es otra entidad

Transformación	Detalle	Justificación
Calendario	Agregación por anuncio y mes dentro de MongoDB ($group); pct_disponibilidad y mes_completo	7 M de filas diarias se reducen a 249 431 sin perder la pregunta de negocio
Derivadas	bano_compartido (de bathrooms_text), longitud_comentario, sin_comentario	Variables útiles para el análisis

Resultado de la carga (verificado contra *COUNT(*)* en SQLite):

Tabla	Filas	Columnas	Llave única
listings	19 187	65	listing_id
hosts	8 335	16	host_id
listing_amenities	505 595	2	(listing_id, amenity)
reviews	527 731	12	review_id
calendario_mensual	249 431	11	(listing_id, fecha_mes)

Las tablas se exportaron a cuatro archivos XLSX (*airbnb_listings.xlsx* con las hojas listings y hosts, *airbnb_reviews.xlsx*, *airbnb_calendario_mensual.xlsx* y *airbnb_amenities.xlsx*). Los identificadores se exportan como texto porque Excel solo conserva 15 dígitos y los IDs de Airbnb llegan a 19 (por ejemplo 1 712 443 307 406 192 155); exportados como número, varios IDs distintos quedarían iguales. El texto de los comentarios se conserva completo en SQLite pero no se exporta a Excel por tamaño.

6. Ejemplo del log

Fragmento del archivo *logs/log_20261011_2151.txt*, generado por la ejecución completa del 11 de octubre de 2026 (*python -m src.pipeline*), que tardó 251 segundos. Cada línea registra fecha y hora, nivel, módulo y mensaje.

```
2026-10-11 21:51:39 | INFO    | etl_airbnb.pipeline | ##### INICIO DEL ETL AIRBNB BOGOTÁ #####
2026-10-11 21:51:39 | INFO    | etl_airbnb.extraccion | Conexión exitosa con MongoDB (mongodb://localhost:27017), base de datos
                    'airbnb_bogota'
2026-10-11 21:51:39 | INFO    | etl_airbnb.extraccion | Colección 'Listings': 19,187 documentos
2026-10-11 21:51:39 | INFO    | etl_airbnb.extraccion | Colección 'Reviews': 527,731 documentos
2026-10-11 21:51:39 | INFO    | etl_airbnb.extraccion | Colección 'Calendar': 7,003,255 documentos
2026-10-11 21:51:42 | INFO    | etl_airbnb.extraccion | Extracción de 'Listings': 19,187 registros, 77 columnas (2.4 s)
2026-10-11 21:51:51 | INFO    | etl_airbnb.extraccion | Extracción de 'Reviews': 527,731 registros, 6 columnas (9.6 s)
2026-10-11 21:52:03 | INFO    | etl_airbnb.extraccion | Extracción agregada de 'Calendar' (listing_id x mes): 249,431 registros
                    (11.7 s)
2026-10-11 21:52:03 | INFO    | etl_airbnb.transformacion | Deduplicación de Listings: 19,187 registros antes, 19,187 después (0
                    eliminados)
2026-10-11 21:52:03 | INFO    | etl_airbnb.transformacion | Precio normalizado a número (símbolos '$' y ',' eliminados); 195
                    anuncios sin precio
2026-10-11 21:52:03 | INFO    | etl_airbnb.transformacion | Categorización por rangos ['Económico', 'Bajo', 'Medio', 'Alto',
                    'Premium']; 659 precios atípicos marcados (> 591,386 COP, Q3+3*IQR), no eliminados
2026-10-11 21:52:03 | INFO    | etl_airbnb.transformacion | minimum_nights: 84 anuncios con estadía mínima > 30 noches marcados
                    (no eliminados)
2026-10-11 21:52:05 | INFO    | etl_airbnb.transformacion | amenities desanidado: 505,595 relaciones anuncio-servicio, 3,588
                    servicios distintos
2026-10-11 21:52:06 | INFO    | etl_airbnb.transformacion | Información del anfitrión separada: 15 columnas movidas a 'hosts'
                    (8,335 anfitriones)
2026-10-11 21:52:07 | INFO    | etl_airbnb.transformacion | Integridad referencial verificada: todas las reseñas apuntan a un
                    anuncio existente
2026-10-11 21:52:15 | INFO    | etl_airbnb.transformacion | Calendario mensual: 249,431 filas; 38,374 corresponden a meses
                    parciales (bordes del rango)
2026-10-11 21:52:15 | INFO    | etl_airbnb.transformacion | === Fin de la transformación: listings=19,187, hosts=8,335,
                    listing_amenities=505,595, reviews=527,731, calendario_mensual=249,431 ===
2026-10-11 21:52:18 | INFO    | etl_airbnb.carga | Tabla 'reviews' cargada: 527,731 filas, 12 columnas (2.2 s)
2026-10-11 21:52:21 | INFO    | etl_airbnb.carga | Verificación OK: 'listings' tiene 19,187 filas, igual a lo transformado
2026-10-11 21:52:21 | INFO    | etl_airbnb.carga | Verificación OK: 'hosts' tiene 8,335 filas, igual a lo transformado
2026-10-11 21:52:21 | INFO    | etl_airbnb.carga | Verificación OK: 'listing_amenities' tiene 505,595 filas, igual a lo
                    transformado
2026-10-11 21:52:21 | INFO    | etl_airbnb.carga | Verificación OK: 'reviews' tiene 527,731 filas, igual a lo transformado
2026-10-11 21:52:21 | INFO    | etl_airbnb.carga | Verificación OK: 'calendario_mensual' tiene 249,431 filas, igual a lo
                    transformado
2026-10-11 21:52:45 | INFO    | etl_airbnb.carga | XLSX generado: ...\datos\salida\airbnb_listings.xlsx (11.5 MB, 24.4 s)
2026-10-11 21:53:37 | INFO    | etl_airbnb.carga | XLSX generado: ...\datos\salida\airbnb_calendario_mensual.xlsx (10.1 MB, 51.6
                    s)
2026-10-11 21:55:26 | INFO    | etl_airbnb.carga | XLSX generado: ...\datos\salida\airbnb_reviews.xlsx (36.5 MB, 108.8 s)
2026-10-11 21:55:50 | INFO    | etl_airbnb.carga | XLSX generado: ...\datos\salida\airbnb_amenities.xlsx (5.7 MB, 24.6 s)
2026-10-11 21:55:50 | INFO    | etl_airbnb.pipeline | ##### ETL FINALIZADO CORRECTAMENTE en 251.0 s #####
```

El log muestra que la extracción de *Calendar* reporta **249 431 registros y no 7 003 255**: la agrupación por anuncio y mes se ejecuta dentro de MongoDB con un *$group*, de modo que a pandas solo viajan los resultados agregados. Así se evita cargar varios gigabytes en memoria y se conserva la información necesaria para el análisis de disponibilidad (el ETL también permite traer el calendario diario completo con *--calendar completo*).

En esta ejecución no hubo mensajes WARNING ni ERROR porque los datos no tenían duplicados, huérfanos ni valores fuera de rango. Esos niveles se usan cuando, por ejemplo, se eliminan registros duplicados, falta una columna esperada, MongoDB no responde o la verificación de la carga encuentra diferencias; en ese último caso el proceso se detiene con un error.

7. Conclusiones de calidad y utilidad

- **Calidad estructural alta.** Las tres colecciones llegaron completas, sin duplicados y con integridad referencial total. Los problemas son de formato (precio y fechas como texto, booleanos como letras, HTML en los comentarios), y todos se resolvieron de forma automática y verificable.

- **El precio es la variable más delicada.** Tiene errores de captura de cientos de millones de pesos y, en el 18 % de los anuncios, corresponde a una tarifa mensual con descuento. Cualquier análisis de precios debe usar la mediana, excluir los atípicos marcados y separar los anuncios de estadía mensual.
- **Los nulos tienen significado.** La falta de calificación indica un anuncio sin reseñas, no un error; por eso no se imputó. Las 13 columnas totalmente vacías se descartaron.
- **Disponibilidad no es ocupación.** Muchos anuncios tienen el calendario abierto todo el año o bloquean fechas lejanas, así que la disponibilidad debe interpretarse con cuidado y con el indicador de mes completo.
- **Utilidad.** El modelo resultante (anuncios, anfitriones, servicios, reseñas y calendario mensual, unidos por listing_id y host_id) permite responder preguntas de negocio como el precio por localidad y tipo de alojamiento, la concentración de la oferta en operadores profesionales, la evolución de la demanda o los servicios más comunes, directamente con SQL o en Excel.
- **Reproducibilidad.** Todo el proceso se ejecuta con un solo comando, es idempotente (volver a ejecutarlo reconstruye las tablas sin duplicar), verifica sus propios resultados y deja un log por ejecución. Se acompaña de 34 pruebas automáticas.

8. Referencias

Inside Airbnb. (2026). *Get the data – Bogotá, Colombia (corte del 21 de junio de 2026)*. https://insideairbnb.com/get-the-data/

MongoDB, Inc. (s. f.). *$group (aggregation)*. MongoDB Manual. https://www.mongodb.com/docs/manual/reference/operator/aggregation/group/

MongoDB, Inc. (s. f.). *PyMongo documentation – Tutorial*. https://pymongo.readthedocs.io/

The pandas development team. (s. f.). *pandas.DataFrame.to_sql*. https://pandas.pydata.org/docs/reference/api/pandas.DataFrame.to_sql.html

Python Software Foundation. (s. f.). *sqlite3 – DB-API 2.0 interface for SQLite databases*. https://docs.python.org/3/library/sqlite3.html

Python Software Foundation. (s. f.). *Logging HOWTO*. https://docs.python.org/3/howto/logging.html

openpyxl. (s. f.). *openpyxl – A Python library to read/write Excel 2010 xlsx/xlsm files*. https://openpyxl.readthedocs.io/en/stable/

Repositorio de ejemplo del curso. (2026). *ETL-ITM-2026-2*. https://github.com/candesjara/ETL-ITM-2026-2

Repositorio del proyecto. (2026). *ETL Airbnb Bogotá*. https://github.com/Juliam78/itm